ベンチャー体験工房２後期 最終発表
2023/2/6

たんぽぽ画像分類

s1290162 中村善音

たんぽぽ1計画とは

画像: © Tanpopo Mission Team

・国際ステーション上で行われている日本初のアストロバイオロジー実験。

・パンスペルミア説を検証する

・エアロゲル（低密度ガラスの捕獲材）を用いて宇宙塵(micrometeoroid)などを捕集する（捕集実験）。

→その物質を地上で分析する

- 宇宙塵（**宇宙由来**の有機物含有物質）

  → 1mm以下の天然の微粒子

- 地球由来の微粒子（**地球由来**の微生物含有物質）
- スペースデブリ（人工物）

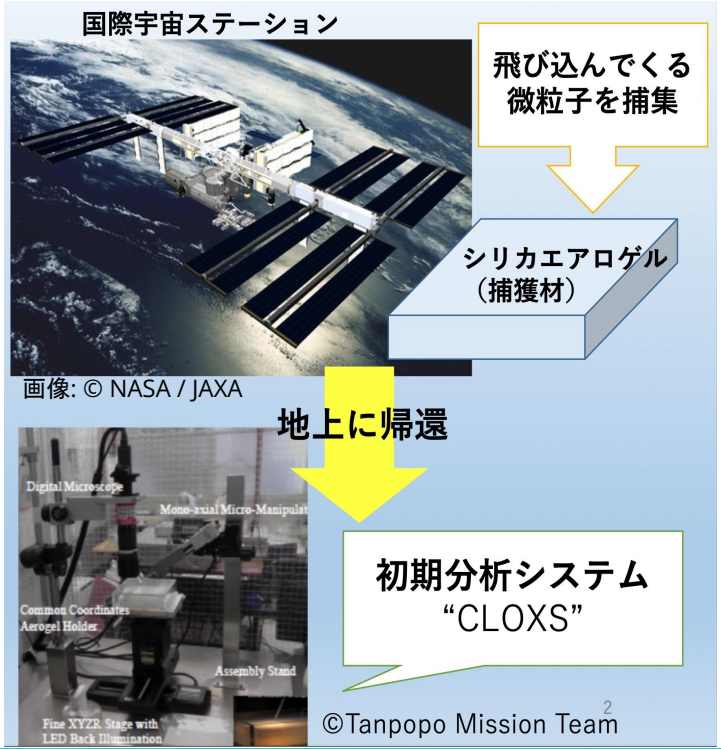

捕集されたトラック (貫入孔)の分類

- トラック（微粒子貫入孔・衝突痕）

  Pit, Carrot, Straight, Teardrop

ゲル中に貫入しており、深さを持つ(=画像枚数が多い)

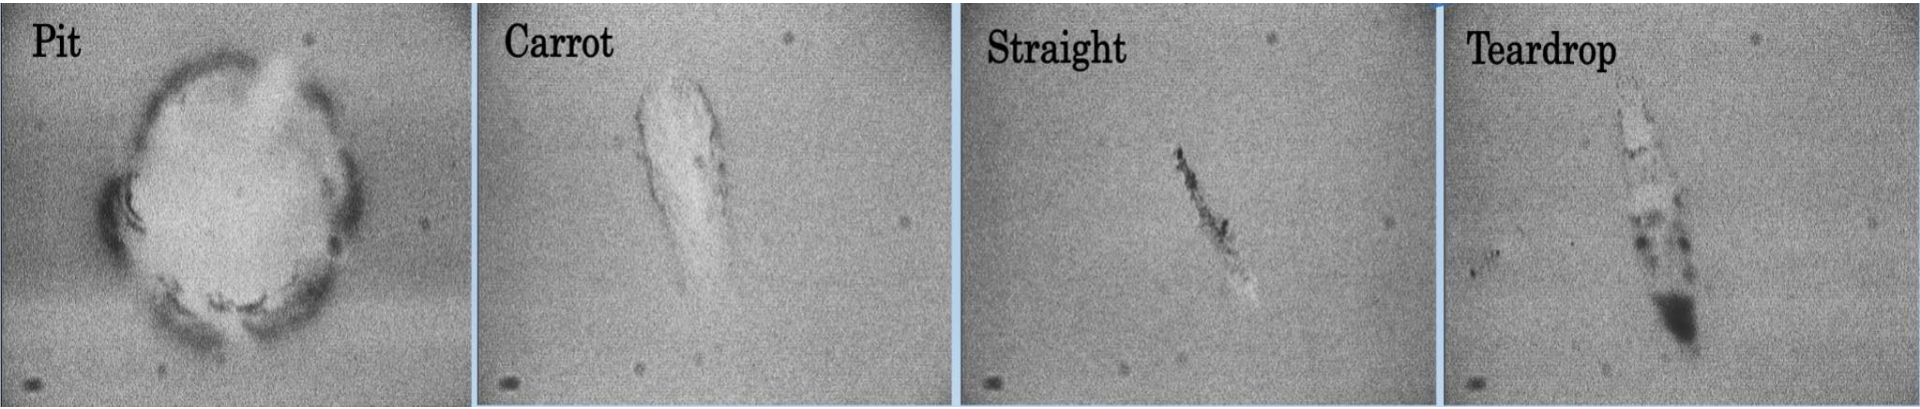

画像: © Tanpopo Mission Team

補修された表面付着物の分類

- 表面付着物（主にゴミ）

  Sputter, Block, Fiber, Bar, A/G fragment

表面のみで、深さはない
(=画像枚数は少ない)

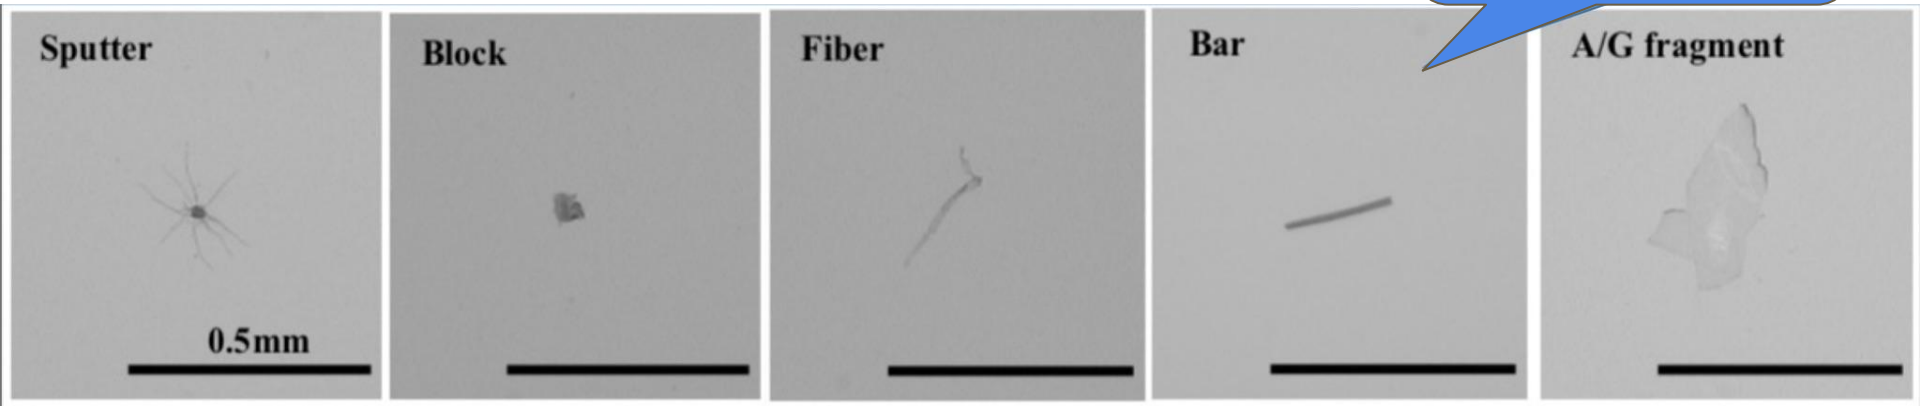

画像: © Tanpopo Mission Team

地上初期分析の流れ -CLOXSによる画像撮影

パネル表面の顕微画像の自動撮像・統合・マッピング

貫入孔候補や表面付着物等の検出・ID付与

貫入孔候補への再訪問と拡大・三次元撮像

研究所による貫入孔の判定・分類・掘削用立体形状の決定

試料配分委員会による詳細分析チームへの配分決定

試料の自動切り出し

CLOXSの一連の流れ

貫入孔画像や付随する各種データをデータベースに格納、各分析チームへ分配

タイプ分類と捕獲粒子の物性推定

- トラック(貫入孔)の形状と捕獲物の物性とはゆるい相関がある

画像: © Tanpopo Mission

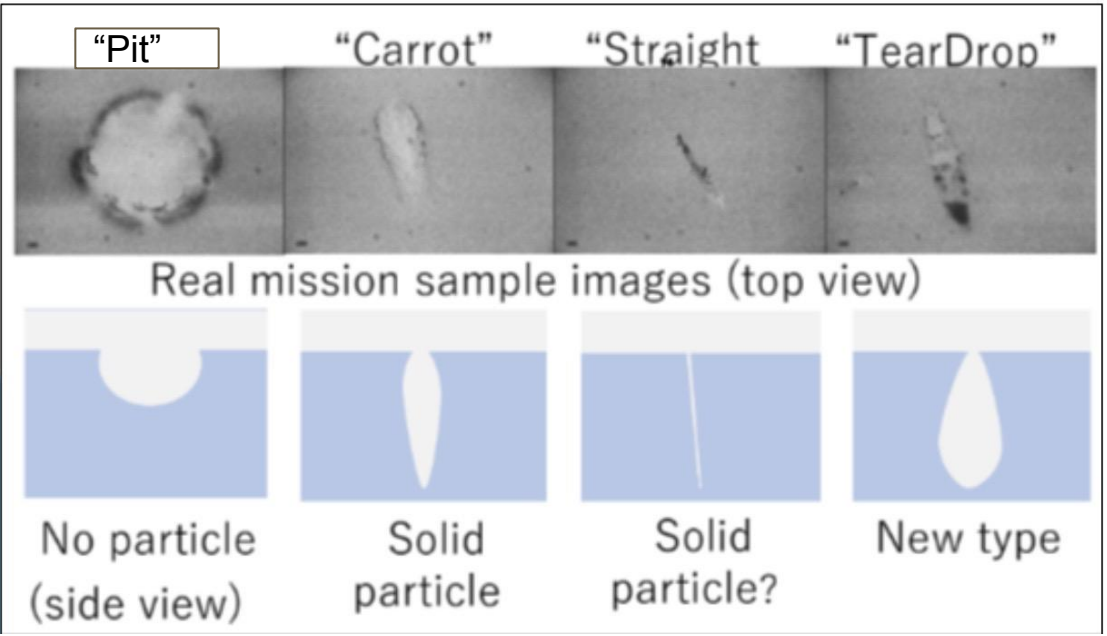

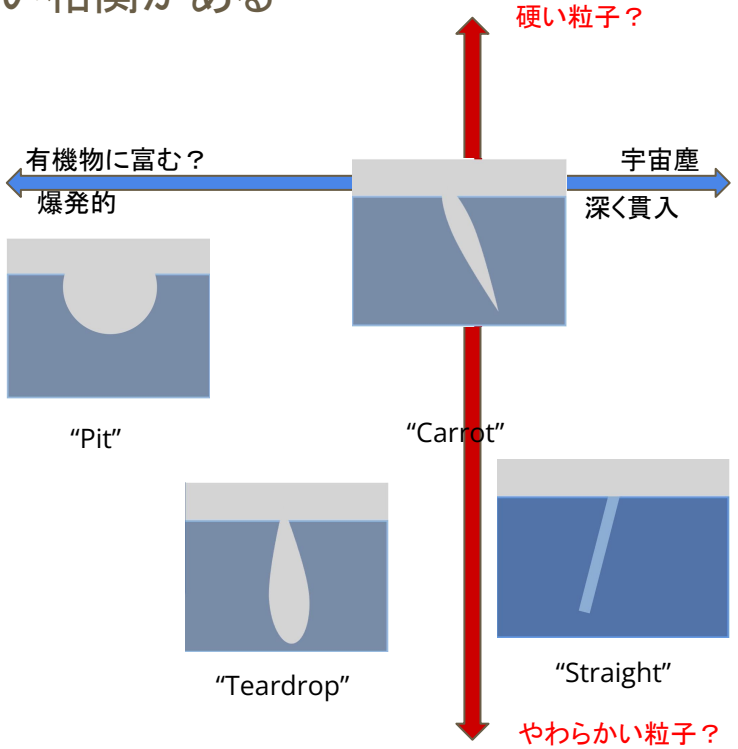

表面付着物の分類

表面付着物の分類

- 桐生さんの論文

  [1] https://web-int.u-aizu.ac.jp/thesis/Thesis2020-Mar/s1250153/s1250153.pdf

- 表面付着物を自動分類したときに、再現率(recall)が70%以上を目標する

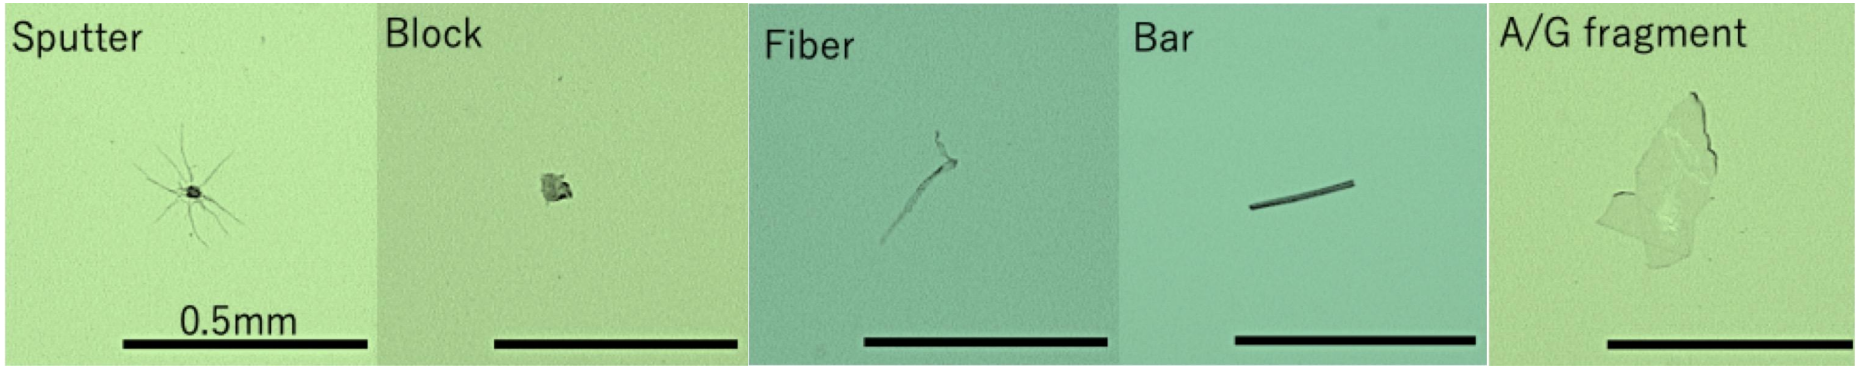

©Tanpopo1 Mission Team

データの前処理（Preprocessing）

- ZCA Whitening

白色化：トレーニングデータの偏りを小さく、また各成分間の相関を無くす

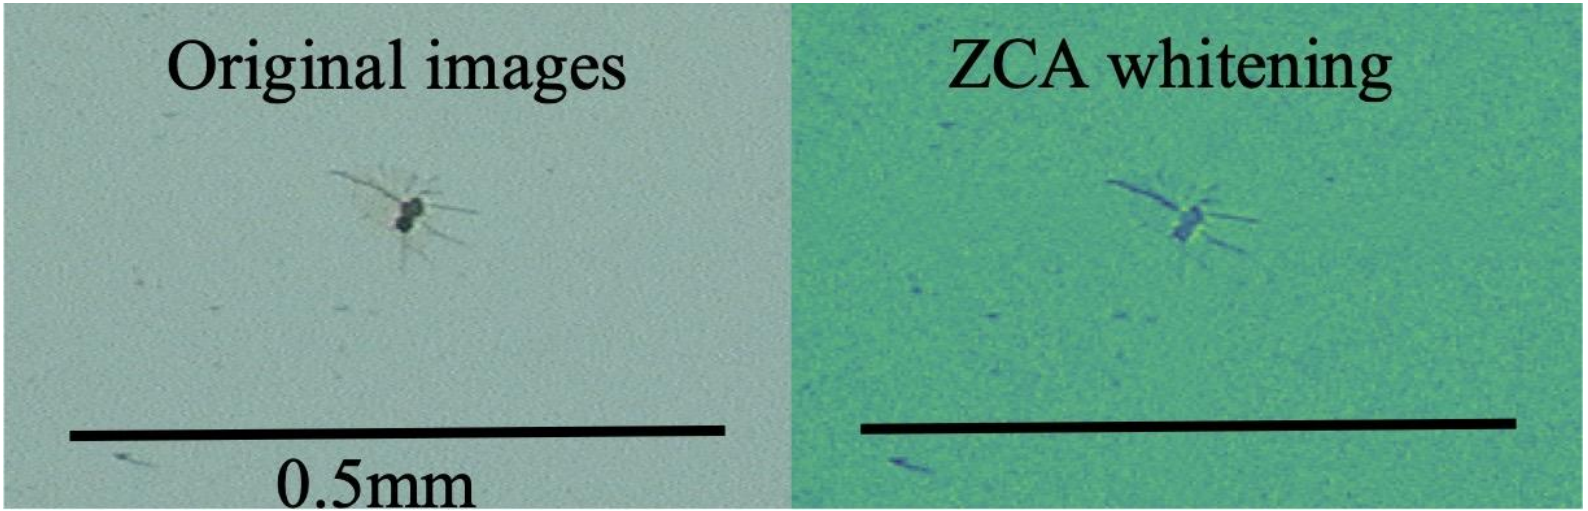

©Tanpopo1 Mission Team

データの前処理

- Thresholding（しきい値処理）

  特定のしきい値以上（もしくは以下）のスコアを持つピクセルだけを抽出する手法

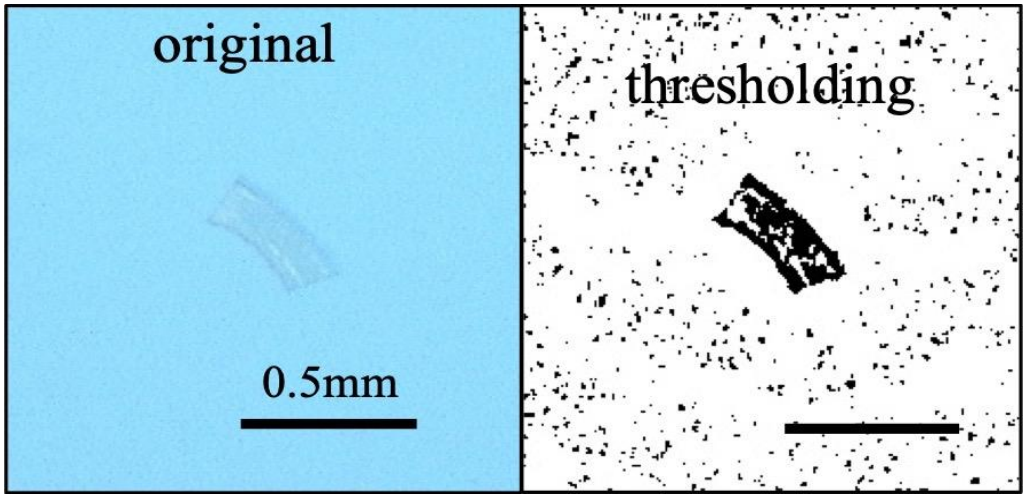

©Tanpopo1 Mission Team

表面付着物の分類

前処理（Preprocessing）

・リサイズ　Resize

・切り取り CenterCrop

データ拡張（Online data Augmentation）

・左右回転　RandomRotation

・上下左右に反転　RandomVerticalFilp, RandomHorizontalFilp

・明るさ、コントラスト、彩度、色相を変化　ColorJitter

表面付着物の分類

ネットワーク（Deep Neural Network）

・VGG16 に **Batch Normalization** を加える

→ 分布の偏りを失くして、学習を安定させる？

→ 学習率（Learning Rate）を大きくできる

局所 min に陥らない

[2] https://proceedings.neurips.cc/paper/2018/file/36072923bfc3cf47745d704feb489480-Paper.pdf

・**Vision Transformer**

→ 計算コスト削減？

Batch Normalization

ミニバッチごとにネットワークのレイヤへの入力の分布が変わる

→ 学習が安定しない

各レイヤごとに入力を正規化

↓

ミニバッチごとの平均・分散を使って

ミニバッチごとに正規化

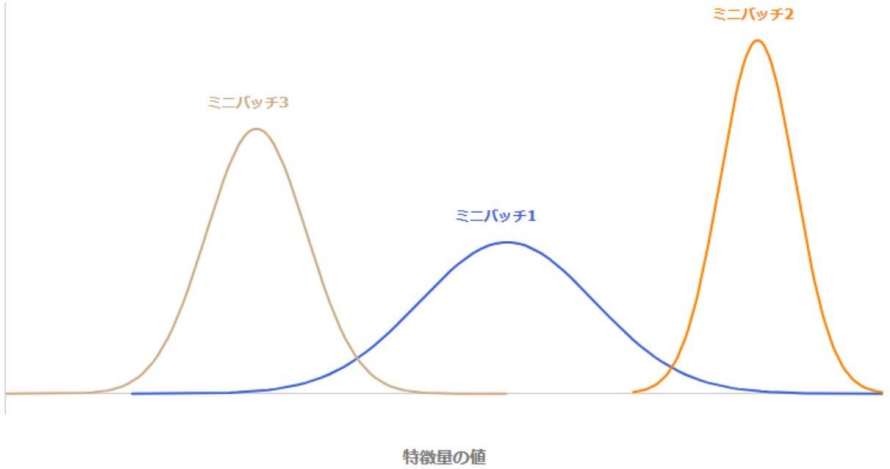

[3] https://data-analytics.fun/2021/09/11/understanding-batch-normalization/

VGG16 + Batch Nomalization

・ReLU層とMaxPlooling層の間にBatch Normalizationを追加（理由: 情報を圧縮する前に正規化したいから？）

(参考) [4] https://www.nature.com/articles/s41598-021-95240-y

・Batch Normalization層のパラメータ、後半の全結合層のパラメータを更新 (勾配計算 True)

・他のパラメータは ImageNetで学習された重みを使用 (Fine Tuning)

合計パラメータ数: 134, 283, 973 (1億3千万)

訓練パラメータ数: 119, 569, 285

```
VGG(
  (features): Sequential(
    (0): Conv2d(3, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (1): ReLU(inplace=True)
    (2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (3): ReLU(inplace=True)
    (4): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (5): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (6): Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (7): ReLU(inplace=True)
    (8): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (9): ReLU(inplace=True)
    (10): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (11): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (12): Conv2d(128, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (13): ReLU(inplace=True)
    (14): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (15): ReLU(inplace=True)
    (16): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (17): ReLU(inplace=True)
    (18): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (19): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (20): Conv2d(256, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (21): ReLU(inplace=True)
    (22): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (23): ReLU(inplace=True)
    (24): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (25): ReLU(inplace=True)
    (26): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (27): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
    (28): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (29): ReLU(inplace=True)
    (30): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (31): ReLU(inplace=True)
    (32): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))
    (33): ReLU(inplace=True)
    (34): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True, track_running_stats=True)
    (35): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)
  )
  (avgpool): AdaptiveAvgPool2d(output_size=(7, 7))
  (classifier): Sequential(
    (0): Linear(in_features=25088, out_features=4096, bias=True)
    (1): ReLU(inplace=True)
    (2): Dropout(p=0.5, inplace=False)
    (3): Linear(in_features=4096, out_features=4096, bias=True)
    (4): ReLU(inplace=True)
    (5): Dropout(p=0.5, inplace=False)
    (6): Linear(in_features=4096, out_features=5, bias=True)
  )
)
```

Transformer

・CNN, RNNなどを使わないで、Attention 機構のみを使う

・Attention

→ どの情報に注目すべきか判断して情報を処理

・Encoder, Decoder

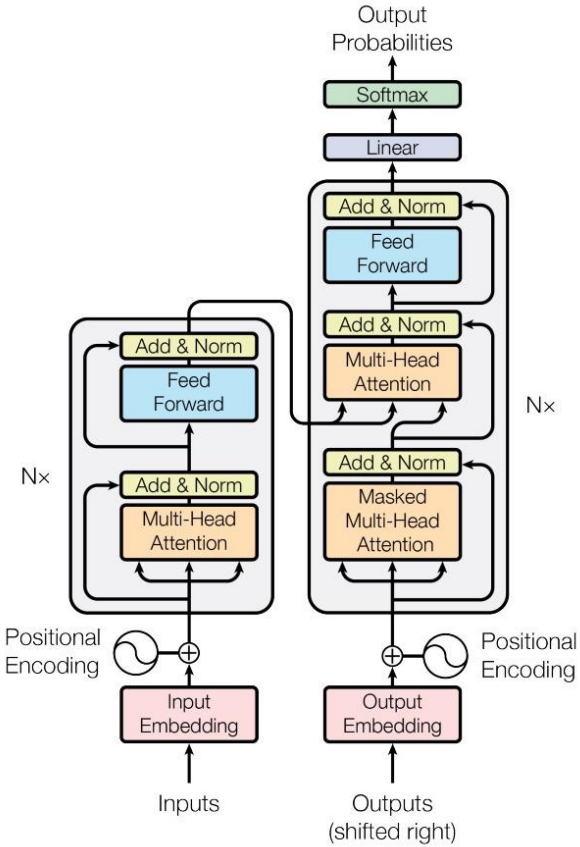

[5]
https://proceedings.neurips.cc/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf

Vision Transformer (ViT)

・Transformer の Encoder 部分を使う

・画像パッチを単語のように扱う

・入力: CLS token 画像全体の特徴を表すベクトル (分類タスクにおいて重要)

・Higging Face

大規模データセットによる事前学習＋ファインチューニング

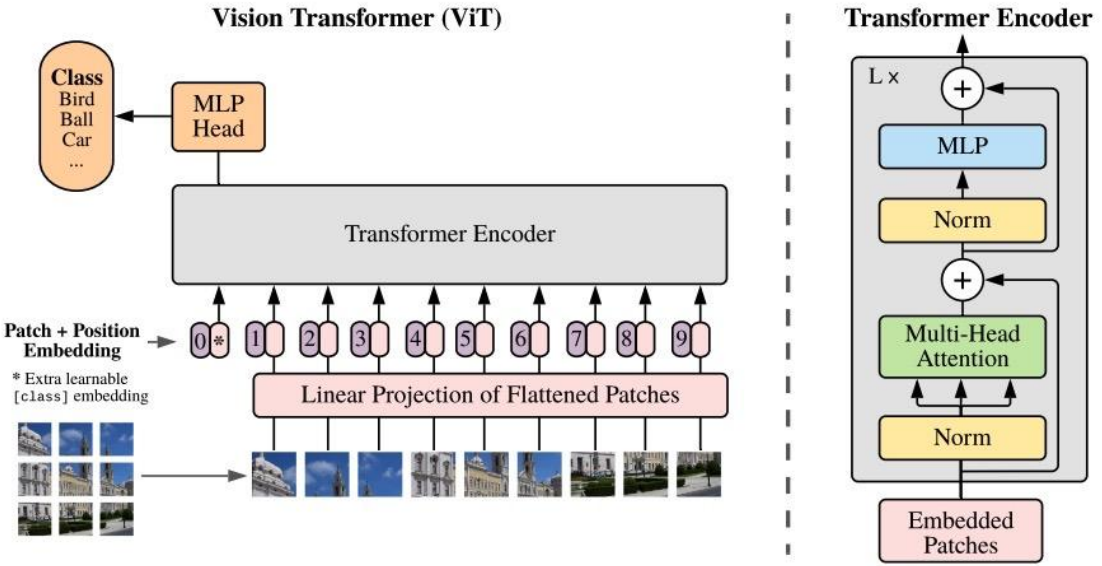

[6] https://arxiv.org/pdf/2010.11929.pdf

Vision Transformer

・google のImageNet(2.1万クラス)で事前学習されたモデル

(google/vit-base-patch16-224-in21k)を使用

・最後に分類の出力として全結合層 (nn.Linear) を追加

・最後の層のパラメータのみ更新 (勾配計算 True)

合計パラメータ数: 86, 393, 093 (8千万)

訓練パラメータ数: 3, 845

交差検証 (K-Cross-validation)

K = 5　Train data : Validation data = 4 : 1 = 196 : 49 (Train data = 49x5 = 245)

1 st	Validation	Train	Train	Train	Train
2 nd	Train	Validation	Train	Train	Train
3 rd	Train	Train	Validation	Train	Train
4 th	Train	Train	Train	Validation	Train
5 th	Train	Train	Train	Train	Validation

交差検証 (Cross Validation) の結果

5-Fold **Accuracy**

- **ViT**

  平均 99.6　標準偏差 0.0067

- **VGG16 + BatchNormalization**

  平均 100.0　標準偏差 0.0000

- **VGG16**

  平均 93.9　標準偏差 0.1166

- **EfficientNet**

  平均 88.2　標準偏差 3.9573

Git Hub: https://github.com/zen-162/Tanpopo1-surfaceObject/tree/master/Pytorch

テスト結果 1（各クラス 21枚ずつ）

Accuracy: 予測がどの程度当たったか

Network / Class	Sputter	Fiber	Block	Bar	A/G Fragment
Vision Transformer	99.8±0.38	97.9±0.38	97.1±0.00	99.0±0.00	96.2±0.00
VGG16 + Batch Normalization	100.0±0.00	98.1±0.00	99.8±0.38	99.0±0.00	98.9±0.38
VGG16	98.9±0.71	96.0±1.52	99.0±0.60	98.5±0.47	93.9±0.97
EfficientNet-B2	94.1±1.11	90.9±1.29	93.7±0.97	95.0±1.11	92.0±0.97

テスト結果 2

Recall: 実際にSputterであるもののうち、Sputterと予測した割合

Network / Class	Sputter	Fiber	Block	Bar	A/G Fragment
Vision Transformer	100.0±0.00	90.5±1.52	95.0±0.00	100.0±0.00	90.5±0.00
VGG16 + Batch Normalization	100.0±0.00	95.2±0.00	99.1±1.82	95.5±0.00	100.0±0.0
VGG16	97.2±2.26	84.2±4.86	99.1±1.82	94.5±1.62	93.1±4.29
EfficientNet-B2	85.0±3.13	73.0±3.82	81.6±2.86	91.6±2.58	87.2±4.09

テスト結果 3

Precision: Sputterと予測したうち、実際にSputterである割合

Network / Class	Sputter	Fiber	Block	Bar	A/G Fragment
Vision Transformer	99.0±1.90	100.0±0.00	90.5±0.00	95.2±0.00	90.5±0.00
VGG16 + Batch Normalization	100.0±0.00	95.2±0.00	100.0±0.00	100.0±0.00	94.3±1.90
VGG16	97.1±3.81	99.0±1.90	96.2±3.56	98.1±2.33	75.2±3.56
EfficientNet-B2	85.7±4.26	86.7±1.90	88.6±2.33	82.9±3.81	70.5±1.90

愛犬のチワワと他のチワワの分類

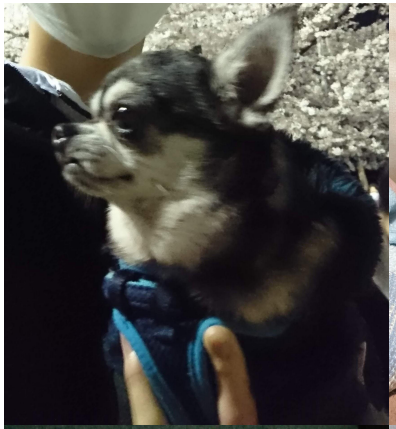


130枚

188枚




議論 Discussion

愛犬のチワワと他のチワワの分類

テスト結果

・VGG16+Batch Normalization

```
Mydog
VGG16 + Batch Normalization network
['myChihuahua', 'ohterChihuahua']
[[14  0]
 [18  0]]

Accuracy :  [43.8 43.8]
Recall :  [43.8  nan]
Precision :  [100.   0.]
```

・Vision Transformer

```
Mydog
Vision Transformer network
['myChihuahua', 'ohterChihuahua']
[[14  0]
 [ 1 17]]

Accuracy :  [96.9 96.9]
Recall :  [ 93.3 100. ]
Precision :  [100.   94.4]
```

結論 Conclusion

・表面付着物の分類タスクに対しては、VGG16+Batch Normalizationが効果的

・Vision Transformer 強いアーキテクチャー

- 計算コスト、パラメータ数

  VGG16+Batch Norm: 1億3千万　　ViT: 8千万

- 精度、再現率

トラックの分類

捕集されたトラック (貫入孔)の分類

- トラック（微粒子貫入孔・衝突痕）

  Pit, Carrot, Straight, Teardrop

ゲル中に貫入しており、深さを持つ(=画像枚数が多い)

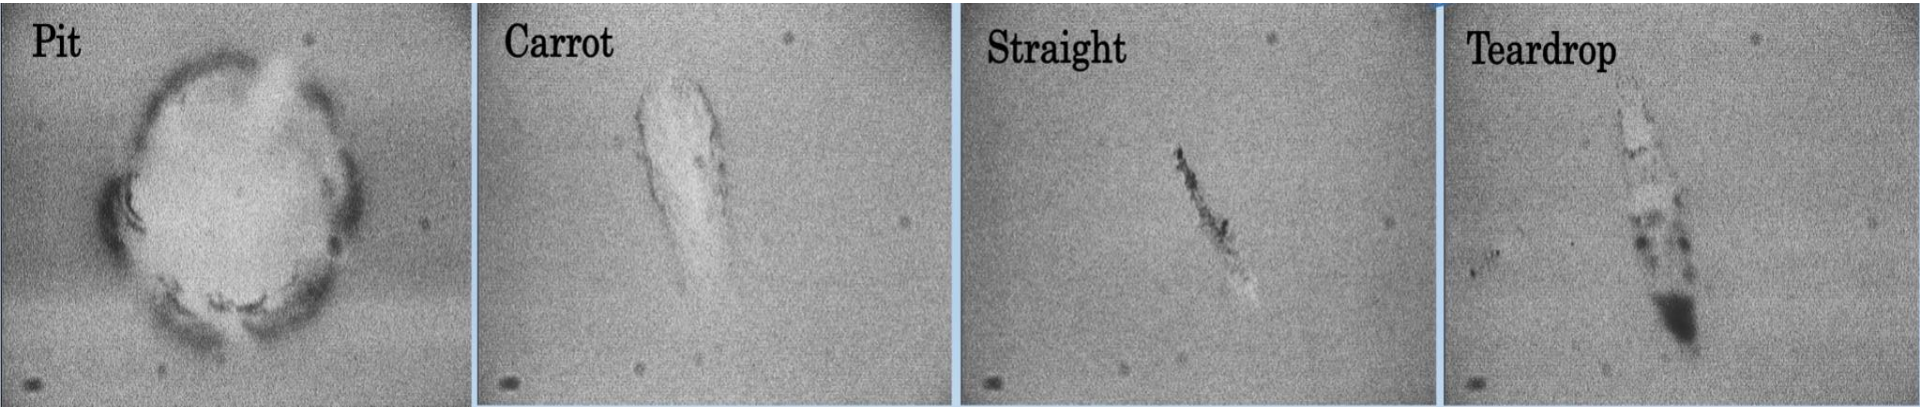

画像: © Tanpopo Mission Team

トラックの分類

- 宮本さんの論文

  [7]https://www.hou.usra.edu/meetings/lpsc2022/pdf/1911.pdf

- MVCNN (Multi-View Convolutional Neural Network)

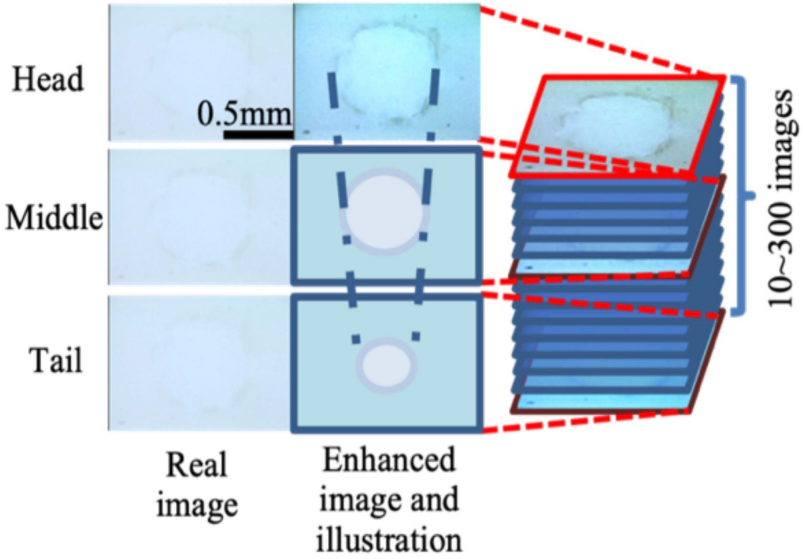

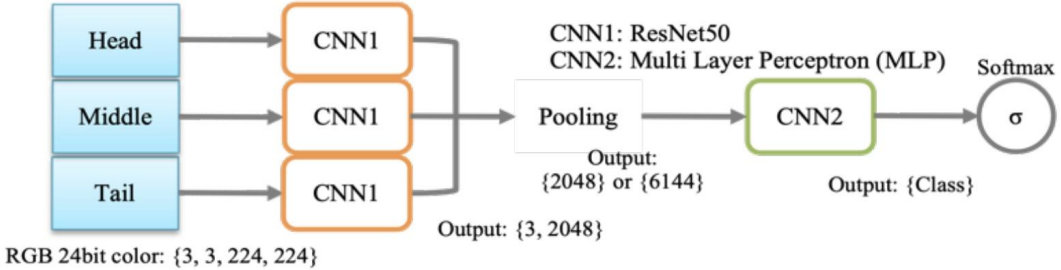

図も本論文より引用

トラックの分類

目標

・表面（Head）部分から自動分類

・再現率(recall)が90~95%以上

興味の対象であるため、高め

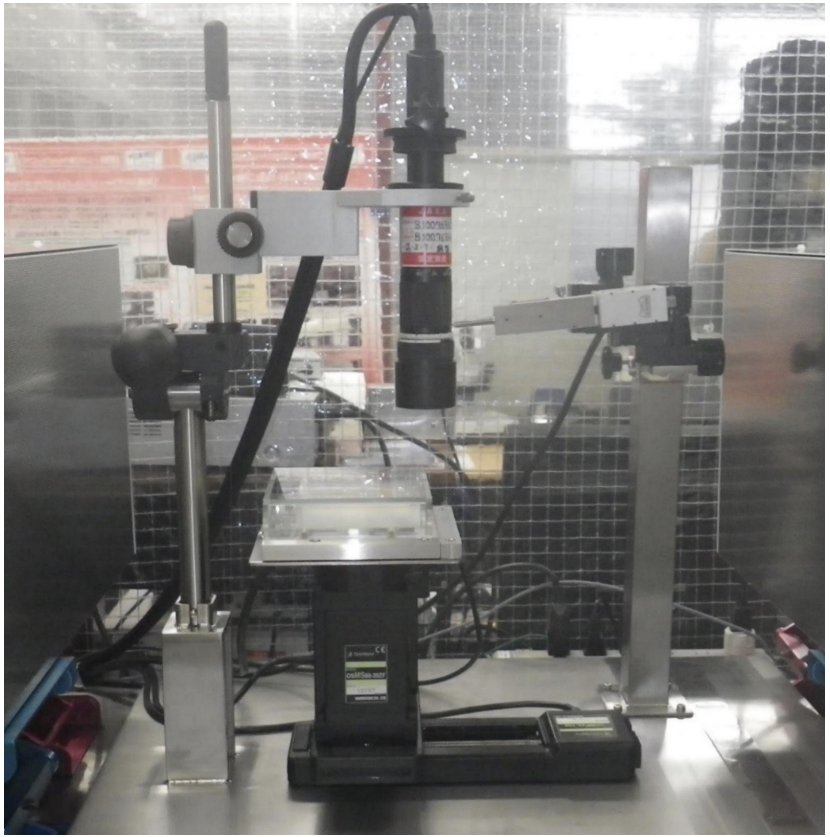

画像: © Tanpopo Mission Team

やったこと

・表面のトラック（Head部分）の画像train: 29枚, validation: 9枚

Pit: 8, Carrot: 10, Straight: 8, Teardrop: 12　　合計: 38

・Vision Transformer

```
Epoch 62/63
 train Loss: 1.1396 Acc: 0.5517        valid Loss: 1.3389 Acc: 0.5556
Epoch 63/63
 train Loss: 1.0652 Acc: 0.4483        valid Loss: 1.3389 Acc: 0.5556
Training complete in 1m 13s
Best val Acc: 0.555556
Best val Loss: 1.299607
```

```
Track Validation
Vision Transformer network
class_names:  ['1Pit', '2Carrot', '3Straight', '4Teardrop']
[[2 0 0 0]
 [1 0 0 1]
 [0 0 0 2]
 [0 0 0 3]]
```

課題

・データの整理

　　枚数を増やす→ ラベル付け

SD1A0298T	D1	Space	2016A	2015 May 26 - 2016 June 13 (384 days)	245	Carrot

・前処理、データ拡張の工夫

　　ZCA whitening

　　しきい値処理

　　その他

```
'train': transforms.Compose([
    # データオグメンテーション，前処理
    transforms.Resize(256), # リサイズ
    transforms.CenterCrop(resize), # 切り取り
    transforms.RandomRotation(45), # ランタムに回転
    transforms.ColorJitter(), # ランダムに明るさ、コントラスト、彩度、色相を変化
    transforms.RandomHorizontalFlip(), # ランダムに左右(水平)反転
    transforms.RandomVerticalFlip(), # ランダムに上下(垂直)反転
    transforms.ToTensor(),
    transforms.RandomErasing(), # ランダムに選択した領域を除去する
    #transforms.Normalize(mean, std), # 正規化
    transforms.Lambda(ZCAWhiteningTransform(mean, std)), # ZCA whitening
]),
```

現状のモデルの評価（スライド外）

前処理、データ拡張としてZCA Whitening 以外を適応

ネットワークにVGG16を使用

True/Predict	Sputter	Fiber	Block	Bar	A/G Fragment	Accuracy (%)	Precision (%)	Recall (%)
Sputter	20	1	0	0	0	98.1	95.2	95.2
Fiber	0	21	0	0	0	98.1	100	91.3
Block	0	1	20	0	0	96.2	95.2	87.0
Bar	1	1	3	15	1	93.3	71.4	93.8
A/G Fragment	0	0	0	0	21	99.0	100	95.5

やったこと（メモ）

・表面付着物の分類

　　ZCA Whitening, VGG16, 交差検証, 転移学習

・モデルをViTに変えて実装してみた、、

・水増し, Offline Augmentation→10倍、リソース足りない

　　-> Online Augmentation

・PyTorch での実装

　　VGG16, Fold-out, 転移学習

（中間まで）

やること(メモ)

・表面付着物

- 本のレビュー
- 画像の枚数を増やしたら、Google Colaboratryでの実行がうまくいかない

  -> プロセスのキャッシュ？

  -> VGG16 モデルをVision Transformerに変える？

- Vision Transformer (Hugging Face)

  VGG16 + Batch Normalization

  efficientNet

・トラック

- image sequence

  -> context approach (Multi View CNN, LSTM, Vision Transformer)

  classification より object detection の方がいいのでは？

アンサンブル学習、画像の位置、長さのみを扱うモデルを準備

教師あり（明確分類されているものデータで）→教師なし（中間的なデータで）

表面だけから判断（分類）できれば CLOXSのシステムとしても扱いやすい？

参考文献 References

[1] KIRYU, Honoka. “Automatic Classification of Surface Objects on Aerogel Images for the Tanpopo Mission” University of Aizu, Graduation Thesis. March, 2021
https://web-int.u-aizu.ac.jp/thesis/Thesis2020-Mar/s1250153/s1250153.pdf

[2] Bjorck, Nils, et al. "Understanding batch normalization." *Advances in neural information processing systems* 31 (2018).
https://proceedings.neurips.cc/paper/2018/file/36072923bfc3cf47745d704feb489480-Paper.pdf

[3] Batch Normalizationを理解する
https://data-analytics.fun/2021/09/11/understanding-batch-normalization/ (参照 2022-12-12)

[4] Yang, Haoyan, et al. "A novel method for peanut variety identification and classification by Improved VGG16." *Scientific Reports* 11.1 (2021): 1-17.
https://www.nature.com/articles/s41598-021-95240-y

参考文献 References

[5] Vaswani, Ashish, et al. "Attention is all you need." *Advances in neural information processing systems* 30 (2017). https://proceedings.neurips.cc/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf

[6] Dosovitskiy, Alexey, et al. "An image is worth 16x16 words: Transformers for image recognition at scale." *arXiv preprint arXiv:2010.11929* (2020). https://arxiv.org/pdf/2010.11929.pdf

[7] Miyamoto, Y., et al. "Classification of Track Types in Tanpopo Mission by Deep Learning." *LPI Contributions* 2678 (2022): 1911. https://www.hou.usra.edu/meetings/lpsc2022/pdf/1911.pdf

ご清聴ありがとうございました。